

基于实时电价与支持向量分位数回归的 短期电力负荷概率密度预测方法

何耀耀¹, 刘瑞¹, 撒奥洋²

- (1. 过程优化与智能决策教育部重点实验室(合肥工业大学), 安徽省 合肥市 230009;
2. 山东电力集团 青岛供电公司调控中心, 山东省 青岛市 266300)

Short-Term Power Load Probability Density Forecasting Method Based on Real Time Price and Support Vector Quantile Regression

HE Yaoyao¹, LIU Rui¹, HAN Aoyang²

- (1. Key Laboratory of Process Optimization and Intelligent Decision-making (Hefei University of Technology),
Ministry of Education, Hefei 230009, Anhui Province, China; 2. Qingdao Power Supply Company Control Center,
Shandong Electric Power Group, Qingdao 266300, Shandong Province, China)

ABSTRACT: In the environment of smart grid, real-time price has bigger influence on the power consumption pattern of power consumers. In order to improve the accuracy of the short-term power load forecasting considering real-time price, and reflect the uncertainty of power load preferably, this paper proposed a support vector quantile regression (SVQR) method. By means of introducing slack variables to construct the lagrange function, the results of power load forecast under different quantiles at any time in a day were evaluated. Meantime, SVQR was combined with kernel density estimation by adopting the Epanechnikov kernel function to perform short-term power load probability density forecasting, which can obtain accurate range of future load. The historical load and real time price data of Singapore were adopted to proceed short-term power load probability density forecasting. The results demonstrate that this method can well solve short-term power load probability density forecasting problem considering real-time price.

KEY WORDS: smart grid; support vector quantile regression (SVQR); real-time price; probability density forecasting; kernel density estimation

摘要: 智能电网环境下, 实时电价对用户用电模式的影响较

大, 为了提高考虑实时电价的短期电力负荷预测精度, 更好地反映电力负荷的不确定性。提出了支持向量分位数回归方法, 通过引入松弛变量构造 Lagrange 函数, 得出不同分位点下的未来一天任意时刻电力负荷的预测结果。同时采用 Epanechnikov 核函数, 将 SVQR 与核密度估计相结合, 进行短期电力负荷概率密度预测, 可得到未来负荷准确的波动范围。以新加坡的历史负荷和实时电价数据为例, 进行短期电力负荷概率密度预测, 结果表明该方法能够较好地解决考虑实时电价的短期电力负荷概率密度预测问题。

关键词: 智能电网; 支持向量分位数回归; 实时电价; 概率密度预测; 核密度估计

0 引言

短期电力负荷预测对电力系统的调度、规划和生产均有很大影响。准确的负荷预测有助于保障电力系统的安全稳定运行^[1-3]。在智能电网环境下, 大量分布式电源和可再生能源接入电网, 成为坚强智能电网不可缺少的重要环节。但是, 可再生能源的波动性和间歇性将对价格导向的电价市场带来重大影响, 一定程度上增加发电和需求双方的不确定性, 增加电力负荷的预测难度。

随着智能电网的发展, 人们对根据电能需求结合实时电价调整其用电模式的需求越来越高, 这使得负荷预测变得更为复杂。在智能电网环境下, 影响短期负荷预测准确性的因素除了历史负荷和气象因素外, 实时电价对短期负荷预测的精度影响也很显著。如果忽略这一重要因素, 负荷预测结果可

基金项目: 国家自然科学基金项目(71401049); 安徽省自然科学基金项目(1408085QG137); 高等学校博士学科点专项科研基金资助课题(20130111120015)。

Project Supported by National Natural Science Foundation of China(71401049); Project supported by Anhui Provincial Natural Science Foundation (1408085QG137); Project Supported by Specialized Research Fund for the Doctoral Program of Higher Education (20130111120015).

能存在重大偏差,失去应用价值,甚至有可能造成重大的经济损失。目前在电力负荷预测方面采用的方法包括神经网络^[4]、模糊理论^[5-6]、组合预测^[7]、支持向量回归^[8-9]等,考虑实时电价的负荷预测研究还不多见^[10]。

电力负荷概率密度预测方法通过构造被预测负荷的概率密度函数,获得比点预测和区间预测更多的信息,是最为详尽的预测方法^[11-12]。因此,如果能够获得实时电价影响下未来负荷的概率分布函数,并分析其预测结果可能的波动范围,可以为电力系统决策人员提供更多的决策信息,避免重大的经济损失。然而,电力负荷的变化具有高度的不确定性,构造的概率密度函数很难准确的反映未来负荷的变化范围。

智能电网环境下,负荷预测精度受经济、环境和实时电价等多种不确定因素的影响,其中,实时电价是影响负荷预测精度的一个重要因素。本文提出了支持向量分位数回归(support vector quantile regression, SVQR)与核密度估计相结合的预测方法,研究了考虑实时电价的电力负荷概率密度预测技术,得出了未来一天不同时刻连续的概率密度预测函数和准确的波动区间。通过研究新加坡的实时电价和负荷数据,分析在考虑电价因素和不考虑电价因素下的概率密度函数的区间半径和最高概率点(众数)的情况,并将获得的结果与传统的支持向量回归方法进行了比较。

1 支持向量回归

支持向量机^[8](support vector machines, SVM)是由 Vapnik 等基于统计学习理论和结构风险最小化原理提出的机器学习方法。它在解决小样本、非线性和高维模式识别问题中表现出许多特有的优势,并在很大程度上克服了“维数灾难”和“过学习”等问题,逐渐成为人工智能领域的研究热点。

SVM 用于回归问题称为支持向量回归(support vector regression, SVR)。该方法通过引入 ε -不敏感损失函数 $L^\varepsilon(x, y, f)$,即 ε -不敏感损失回归。其函数定义为:

$$L^\varepsilon(x, y, f) = |y - f(x)|_\varepsilon = \max(0, |y - f(x)| - \varepsilon) \quad (1)$$

式中: ε 为正常数; ε -不敏感损失函数的含义为:当 x 点的观察值 y 与预测值 $f(x)$ 之差不超过事先设定的 ε 时,则该点的预测值 $f(x)$ 是无损函数。

支持向量回归的主要思想是将低维的非线性函数转化为高维的线性函数,即通过定义核函数并

采用非线性映射 $\phi: \chi \rightarrow F$ 将输入向量 χ 映射到高维的特征空间 F 中做线性回归,则SVR模型为:

$$f(x) = \omega^T \phi(x) + b \quad (2)$$

式中: ω 为参数向量; b 为阈值,回归问题的目标是通过训练样本集找到一个最优参数 (ω, b) 使得 $f(x)$ 和实际值 y 之间的误差尽可能小,可由下面的式子求解:

$$\min_{\omega, b} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^k |y_i - f(x_i)| \quad (3)$$

式中: C 为惩罚参数; k 为样本量。

2 支持向量分位数回归与短期负荷概率密度预测

2.1 支持向量分位数回归模型

由于普通最小二乘法(ordinary least square, OLS)难以解决响应变量的非对称分布或数据分布较为分散的情况, Koenker 等为此提出了分位数回归方法(quantile regression, QR)^[13-16],可以采用回归变量提供的信息对响应变量的条件分位数进行估计,进而准确地描述解释变量对响应变量变化范围和条件分布形状的影响,从而获得更多的有用信息,便于决策者的科学决策。但是 Koenker 提出的分位数回归是基于线性回归的基础上,难以解决复杂的非线性函数。因此, Shim 等利用半参数方法,将支持向量回归(SVR)和分位数回归(QR)进行优化组合,得到了SVQR模型^[17]。许启发等运用SVQR模型进行多期 VaR 风险测度^[18],得到了较好的预测结果。本文运用此方法与核密度估计相结合进行短期电力负荷概率密度预测,不仅可以得到较好的预测精度,而且还可以得到未来负荷准确的波动范围。

传统的 OLS 方法为线性回归法,对于响应变量的影响因素分析不够全面,而电力系统负荷预测所涉及的因素多而且复杂,使用均值回归进行预测精度较差。Koenker 等于 1978 年提出了分位数回归的思想,不仅保留了解释变量和响应变量的统计信息,而且还在一定程度上消除了异方差的问题。分位数回归的具体思想描述如下:

考虑到 k 个因素 X_1, X_2, \dots, X_k 影响随机变量 Y ,其分布函数为:

$$F(y) = P(Y \leq y) \quad (4)$$

则使 $F(y) \geq \tau$ 的最小 τ 值是 Y 的第 τ 分位数,即:

$$Q(\tau) = \inf\{y: F(y) \geq \tau\}, 0 < \tau < 1 \quad (5)$$

Koenker 等人提出了如下的线性分位数回归模型, 即:

$$Q_Y(\tau|X) = \beta_0(\tau) + \beta_1(\tau)X_1 + \beta_2(\tau)X_2 + \dots + \beta_k(\tau)X_k = X'\beta(\tau) \quad (6)$$

式中: $Q_Y(\tau|X)$ 是响应变量 Y 在解释变量 $X=[X_1, X_2, \dots, X_k]^T$ 下的第 τ 个条件分位数, 分位点 $\tau \in (0, 1)$, $\beta(\tau)$ 是回归系数向量, 它随着分位点 τ 的变化而变动。式(6)中的参数向量 $\beta(\tau)$ 的估计可由下式求解:

$$\min_{\beta} \sum_{i=1}^N \rho_{\tau}(Y_i - X_i'\beta) = \min_{\beta} \sum_{i|Y_i \geq X_i'\beta} \tau |Y_i - X_i'\beta| + \sum_{i|Y_i < X_i'\beta} (1-\tau) |Y_i - X_i'\beta| \quad (7)$$

在对分位数回归进行优化之前, 先定义检验函数, 通过检验函数最小化, 优化估计出最优参数, 检验函数的定义为:

$$\rho_{\tau}(\mu) = \mu(\tau - I(\mu)) \quad (8)$$

其中示性函数为:

$$I(\mu) = \begin{cases} 1, & \mu < 0 \\ 0, & \mu \geq 0 \end{cases} \quad (9)$$

该函数是非对称分段线性函数。

基于上述研究, Takeuchi 等^[19]最早利用支持向量机研究了分位数回归问题, 并提出了支持向量分位数回归模型, 较好地解决了经济系统中的非线性结构与经济行为在不同尾部的异质性。为此, 基于 SVR 模型, 将式(3)中的惩罚函数部分用分位数回归来代替, 得到 SVQR 模型:

$$\min_{\omega_{\tau}, b_{\tau}} \frac{1}{2} \|\omega_{\tau}\|^2 + C \sum_{i=1}^k \rho_{\tau}(y_i - b_{\tau} - \omega_{\tau}^T \phi(x_i)) \quad (10)$$

2.2 基于支持向量分位数回归的短期电力负荷概率密度预测

由前述研究成果可知: 短期电力负荷预测受多种复杂因素的影响, 且这些因素是以线性和非线性方式影响未来负荷预测的精度。本文主要研究历史负荷和实时电价通过 SVQR 模型对短期电力负荷预测的影响。针对短期电力负荷预测, 采用 $u_i = x_i = (z_i, p_i)^T$ 作为其影响因素, 其中 z_i 表示历史负荷, p_i 表示实时电价, 建立用于短期电力负荷预测的 SVQR 模型如下:

$$\min_{\omega_{\tau}, b_{\tau}} \frac{1}{2} \|\omega_{\tau}\|^2 + C \sum_{i=1}^k \rho_{\tau}(y_i - b_{\tau} - \beta_{\tau}^T u_i - \omega_{\tau}^T \phi(x_i)) \quad (11)$$

式中: C 为惩罚参数, b 为阈值, $\phi(\cdot)$ 是非线性映射函数。Shim 为了解决最优化问题(11), 引入松弛

变量并且构造 Lagrange 函数, 其求解结果如下:

$$\begin{cases} \omega_{\tau} = \sum_{i=1}^k (\alpha_i - \alpha_i^*) \phi(x_i) \\ (b_{\tau}, \beta_{\tau})^T = (U^T U)^{-1} U^T (y - K(\alpha - \alpha^*)) \\ Q_{y_i}(\tau|u_i, x_i, \eta) = b_{\tau} + \beta_{\tau}^T u_i + K_i(\alpha - \alpha^*) \end{cases} \quad (12)$$

式中: k 为样本量, α, α^* 为最优的 Lagrange 乘子。同时可以得到 SVQR 模型的支持向量下标集 $I_{SV} = \{t = 1, 2, \dots, k | 0 < \alpha_t < \tau C, 0 < \alpha_t^* < (1-\tau)C\}$, 矩阵 $U = (1, u_i^T)$, 向量 $y = \{y_i | t \in I_{SV}\}$, K_i 为输入空间中的核矩阵, 等价于特征空间中 x_i 和 x_s 的内积, 即 $K(x_s, x_i) = \phi(x_s)^T \phi(x_i), t \in I_{SV}$, 且 $s = 1, 2, \dots, k$, 本文采用的核函数为径向基核函数(RBF)。

$$K(x_s, x_i) = \exp\left(-\frac{(x_s - x_i)^T (x_s - x_i)}{2\sigma_K^2}\right) \quad (13)$$

式中: $\eta = (C, \sigma_K^2)$ 为需要训练的参数集; C 为惩罚参数; σ_K^2 为核函数的自由参数。采用 RBF 核函数作为隐式映射函数来估计解释变量之间的非线性关系。在支持向量分位数回归模型的建立过程中, 参数集 η 的选择对 SVQR 模型的预测结果有重大的影响, 为了得到最优参数, 本文采用 Yuan 提出的广义近似交叉验证(GACV)准则^[20]来训练参数集 η 中的参数, 其中 df 为该模型的自由度。其公式如下:

$$GACV(\eta) = \frac{\sum_{i=1}^k \rho_{\tau}(y_i - Q_{y_i}(\tau|u_i, x_i, \eta))}{k - df} \quad (14)$$

由上述研究可得在不同分位点下的条件分位数, 即电力负荷预测结果 $Q_{y_i}(\tau|u_i, x_i, \eta)$, 同时, 把不同分位点下的分位数作为 Epanechnikov 核函数的输入值进行概率密度预测, 核密度估计的定义如下:

设 X_1, X_2, \dots, X_n 是取自一元连续总体的样本, 在任意点 x 处的总体密度函数 $f(x)$ 的核密度估计定义为:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) \quad (15)$$

式中: $K(x - X_i/h)$ 称为核函数, 本文所采用的核密度估计函数是 Epanechnikov 核函数, 其函数表达式为:

$$\frac{3}{4}(1-u^2)I(|u| \leq 1) \quad (16)$$

式中: $I(|u| \leq 1)$ 为示性函数; h 称为窗宽。

本文的主要思想及逻辑思路如图1所示。

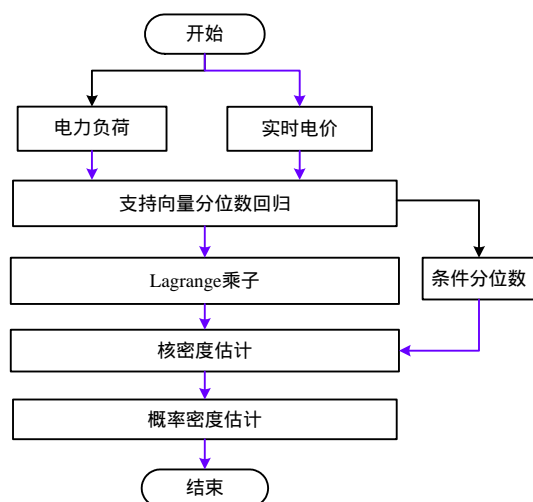


图1 支持向量分位数回归流程图

Fig. 1 Flowchart of SVQR

3 算例仿真

3.1 实时电价与短期负荷的关系分析

本文采用新加坡的电力负荷数据^[21]。新加坡是一个热带雨林气候的国家城市，全年气候湿热，昼夜温差小，每年平均温度在23到32之间。全年4个季节的温度等因素并没有明显的变化。此外，新加坡面积狭小、资源匮乏，水力和风力发电都不大可行，太阳能也无法大面积广泛使用。目前，新加坡电源的80%来自天然气发电，另外也有少量光伏电站并入电网。随着新加坡电力市场的开放，越来越多的用户要求更具竞争力的电价。因此，实时电价成为影响新加坡电力负荷预测精度的一个重要因素。它通过电价信息的及时发布和用户的快速响应，实现对电力系统负荷曲线的调节，以及对用户用电模式的影响。在复杂的智能电网环境下，实时电价的波动会引起负荷的变化，而负荷的变化又会引起电价的波动。图2为新加坡2014年4月7日到15日的电价对负荷的影响图，其中横轴为电价，纵轴为与其相对应的负荷，如图2可知，随着电价的逐渐增长，电力负荷的增长速度逐渐变缓，达到一定程度后，电力负荷保持稳定，说明电价的增长对负荷需求有明显的抑制作用。

算例以新加坡2014年4月7日到16日的历史负荷数据以及2014年4月7日到15日的实时电价数据为基础。在不考虑实时电价的情况下，以4月7日到14日的历史负荷数据为训练输入样本，以4月15日为训练输出样本，以4月8日到15日的历史负荷数据为测试输入样本，对4月16日的24个




图2 负荷电价关系图

Fig. 2 Relational diagram of load and real-time price

时刻进行预测。在考虑实时电价的情况下，以4月7日到14日的历史负荷和实时电价为训练输入样本，以4月15日的电力负荷为训练输出样本。以4月8日到15日的历史负荷和实时电价为测试输入样本，对4月16日的24个时刻进行预测。所有样本都先进行归一化处理。

首先通过选取的训练样本对SVQR模型进行训练，确定其最优参数 $C=8000$ ， $\sigma_K^2=7500$ ，进而获得最优的模型，采用优化后的支持向量分位数回归模型分别在考虑电价和不考虑电价的情况下，对4月16日的24个时刻进行概率密度预测。为了更好地说明此方法的有效性，采用平均绝对百分比误差(mean absolute percentage error, MAPE)和最大相对百分比误差(maximal relative percentage error, MRPE)为比较的标准，即：

$$MAPE = \frac{1}{n} \left(\sum_{i=1}^n \left| \frac{P_i - L_i}{L_i} \right| \right) \times 100\%, \quad i = 1, 2, \dots, n \quad (17)$$

$$MRPE = \max_{1 \leq i \leq n} \left(\left| \frac{P_i - L_i}{L_i} \right| \times 100\% \right) \quad (18)$$

式中： n 表示总的时刻； i 表示第几个时刻； P_i 和 L_i 分别表示第 i 个时刻的预测值和实际值。

3.2 考虑实时电价的短期电力负荷概率密度预测

根据上述内容，运用SVQR方法得到了4月16日的预测结果、预测区间和概率密度曲线。为了更好地说明SVQR方法的优势，图3和图4分别给出了SVQR和RBF分位数回归(radical basis function quantile regression, RBFQR)方法^[11]在考虑实时电价下4月16日24个时段完整的预测区间和预测结果。这两种方法都选取99个分位点为0.01到0.99，间隔为0.01。其中，RBFQR的迭代次数为1000，隐含层节点数为1，惩罚参数为1。SVR的惩罚参数为8000，不敏感损失函数为0.001。




图3 基于实时电价与SVQR的预测结果与预测区间

Fig. 3 Prediction results and prediction intervals based on real-time price and SVQR

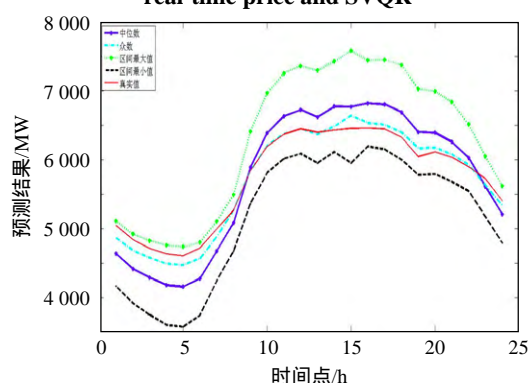


图4 基于实时电价与RBFQR的预测结果与预测区间

Fig. 4 Prediction results and prediction intervals based on real-time price and RBFQR

图5分别给出了第1, 5, 9, 13, 17, 21h的考虑实时电价的概率密度曲线。

从图3、4中可以发现, 实际值始终落在预测

区间内, 但采用SVQR方法的众数预测结果几乎接近真实值曲线, 且波动区间明显小于RBFQR方法的波动区间, 说明本文提出的方法可以准确地刻画电力负荷的波动性。由图5知, 在采用支持向量分位数回归方法进行考虑实时电价因素的短期电力负荷概率密度预测时, 实际值都出现在密度函数曲线上, 除了第5小时的实际值出现在概率密度函数曲线图的尾部之外, 其余的实际值都出现在概率密度函数图的中部, 其中第1, 13, 17小时的实际值都出现在概率密度曲线的最高概率点附近。通过上述分析可得, 所得到的预测值与预测误差不仅可以为电力系统工作人员提供更多的决策信息, 而且也为智能电网环境下短期电力负荷预测提供了一种更好的概率性预测方法。

为了更有效地说明SVQR方法的优势, 本文通过表1、2分别给出了运用SVQR方法在不考虑和考虑实时电价2种情况下预测日的众数、预测区间、区间半径以及预测误差。表3给出了SVQR, SVR和RBFQR方法的预测结果。由表1及表2可知, SVQR在考虑实时电价因素时, 平均绝对误差为0.80%, 其最大相对误差为1.63%, 平均区间半径为370.65。在不考虑电价因素时, 平均绝对误差为1.16%, 其最大相对误差为2.62%, 平均区间半径为362.39。可以看出: 考虑实时电价的平均区间半径大于不考虑电价的平均区间半径, 这说明提高预测精度并确保真实值落于预测区间内需要一定




图5 基于实时电价和SVQR的概率密度曲线图

Fig. 5 Diagram of probability density curve based on real-time price and SVQR

表 1 不考虑电价因素预测结果

Tab. 1 Forecasting results without considering real-time price factor

时间/h	实际值/MW	不考虑电价因素			
		众数/MW	预测区间/MW	区间半径	相对误差/%
0:00	5043.223	5020.992	[4897.682, 5760.853]	431.586	-0.441
1:00	4838.081	4805.468	[4698.829, 5648.879]	475.025	-0.674
2:00	4712.440	4693.054	[4579.878, 5588.178]	504.150	-0.411
3:00	4633.620	4601.172	[4482.692, 5538.235]	527.771	-0.700
4:00	4604.536	4570.971	[4450.722, 5522.032]	535.655	-0.729
5:00	4717.484	4672.906	[4547.609, 5570.873]	511.632	-0.945
6:00	4994.974	4991.264	[4817.123, 5715.326]	449.102	-0.074
7:00	5265.939	5308.306	[5052.120, 5861.999]	404.940	0.805
8:00	5835.769	5906.707	[5510.727, 6146.892]	318.082	1.216
9:00	6193.763	6313.478	[5838.566, 6399.306]	280.370	1.933
10:00	6371.371	6485.820	[5982.498, 6569.707]	293.605	1.796
11:00	6448.545	6548.806	[6026.573, 6635.845]	304.636	1.555
12:00	6400.048	6459.648	[5963.999, 6542.256]	289.128	0.931
13:00	6430.748	6561.919	[6026.666, 6651.128]	312.231	2.040
14:00	6456.482	6625.824	[6065.778, 6719.165]	326.693	2.623
15:00	6459.807	6593.416	[6048.214, 6684.283]	318.035	2.068
16:00	6449.837	6517.667	[5994.720, 6612.175]	308.727	1.052
17:00	6325.235	6403.143	[5898.567, 6487.239]	294.336	1.232
18:00	6046.736	6171.674	[5729.758, 6271.105]	270.673	2.066
19:00	6116.152	6188.687	[5755.951, 6286.053]	265.051	1.186
20:00	6037.059	6105.063	[5709.652, 6255.430]	272.889	1.126
21:00	5897.332	5962.970	[5612.598, 6194.572]	290.987	1.113
22:00	5727.940	5684.949	[5399.661, 6065.334]	332.836	-0.751
23:00	5403.071	5380.791	[5164.030, 5922.694]	379.332	-0.412

表 2 考虑电价因素预测情况

Tab. 2 Forecasting results of considering real-time price factor

时间/h	实际值/MW	考虑电价因素			
		众数/MW	预测区间/MW	区间半径	相对误差/%
0:00	5043.223	5022.139	[4898.076, 5833.316]	467.619	-0.418
1:00	4838.081	4801.545	[4707.098, 5735.528]	514.215	-0.755
2:00	4712.440	4680.408	[4591.329, 5682.552]	545.611	-0.680
3:00	4633.620	4590.256	[4497.074, 5638.555]	570.740	-0.936
4:00	4604.536	4559.900	[4465.288, 5624.291]	579.501	-0.969
5:00	4717.484	4662.479	[4560.776, 5668.205]	553.714	-1.166
6:00	4994.974	4977.568	[4817.694, 5796.92]	489.612	-0.348
7:00	5265.939	5301.091	[5050.685, 5927.106]	438.210	0.668
8:00	5835.769	5892.501	[5508.547, 6180.467]	335.960	0.972
9:00	6193.763	6289.139	[5842.528, 6376.283]	266.877	1.540
10:00	6371.371	6475.118	[5992.586, 6555.54]	281.476	1.628
11:00	6448.545	6512.394	[6043.406, 6603.904]	280.248	0.990
12:00	6400.048	6426.238	[5964.207, 6523.208]	279.500	0.409
13:00	6430.748	6517.305	[6033.309, 6618.884]	292.787	1.346
14:00	6456.482	6445.709	[6101.177, 6637.116]	267.969	-0.167
15:00	6459.807	6513.230	[6065.626, 6620.881]	277.627	0.827
16:00	6449.837	6433.825	[6006.804, 6550.285]	271.740	-0.248
17:00	6325.235	6363.514	[5897.745, 6461.268]	281.761	0.605
18:00	6046.736	6134.707	[5727.616, 6289.516]	280.950	1.455
19:00	6116.152	6152.804	[5755.238, 6303.991]	274.376	0.599
20:00	6037.059	6078.573	[5708.549, 6275.149]	283.300	0.688
21:00	5897.332	5931.149	[5616.564, 6221.061]	302.248	0.573
22:00	5727.940	5673.382	[5400.057, 6104.946]	352.444	-0.953
23:00	5403.071	5378.679	[5162.615, 5977.011]	407.198	-0.451

程度的增加区间半径。此外,由上述预测结果也可以看出,在采用同样的SVQR方法进行短期电力负荷预测时,考虑实时电价因素的预测误差远小于不考虑电价因素的预测误差。这说明在智能电网环境下进行电力负荷概率密度预测,需要充分考虑实时电价因素,以避免较大的预测误差和经济损失。

通过比较表3中几种方法的预测误差结果可知,在采用同样的方法进行短期电力负荷预测时,考虑实时电价因素的预测结果优于不考虑电价因素的预测结果;SVQR方法无论在考虑实时电价还是不考虑电价的情况,其众数的预测结果都优于其它方法。综上所述,无论采用何种方法,实时电价因素都应作为短期电力负荷预测的一个重要因素,同时也说明了SVQR方法对于短期负荷预测的有效性。图6给出了考虑实时电价时,SVQR概率密度预测方法的中位数和众数的预测误差,可以看出,中位数的误差明显高于众数的误差。

表3 SVR、SVQR和RBFQR方法的预测误差

Tab. 3 Forecasting errors of SVR,SVQR and RBFQR method

算法	不考虑电价因素		考虑电价因素	
	MAPE/%	MRPE/%	MAPE/%	MRPE/%
SVR	2.15	6.42	2.04	9.95
SVQR(众数)	1.16	2.62	0.80	1.63
RBFQR(众数)	2.53	4.83	1.51	3.56

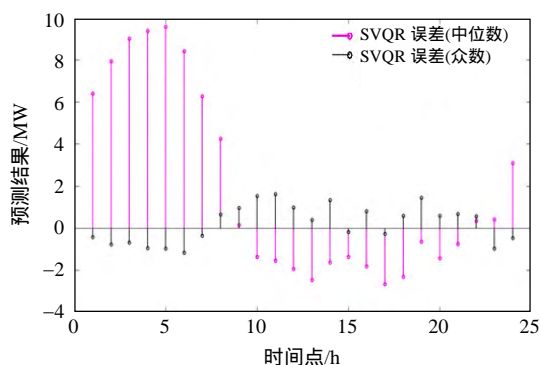


图6 负荷预测误差图

Fig. 6 Diagram of load forecasting errors

4 结论

考虑到实时电价对短期电力负荷预测的影响,本文提出了基于支持向量分位数回归的电力负荷概率密度预测方法,分别研究了不考虑实时电价因素和考虑电价因素的情况,得出以下结论:

1) 本文给出了SVQR和RBFQR方法的预测区间结果,发现实际值始终落在预测区间内。采用SVQR方法的众数预测结果几乎与实际值曲线一

致,且其波动区间明显小于RBFQR方法的波动区间。说明本文提出的方法可以准确地刻画电力负荷的波动性,并以较大的概率出现在概率密度曲线的众数处。

2) 采用本文方法,同时可以得到预测区间和区间半径。此外,本文通过概率密度预测可以得知,在考虑实时电价因素时,预测精度要高于不考虑电价因素的情况,而且与SVR,RBFQR方法进行比较,得出的预测结果也更加准确。但是在考虑电价因素时,获得的平均区间半径要大于不考虑实时电价的情况。这说明在利用实时电价提高概率密度预测方法精度的同时,需要一定程度的加宽预测区间半径。

参考文献

- [1] 康重庆,夏清,刘梅.电力系统负荷预测[M].北京:中国电力出版社,2007:241-250.
Kang Chongqing, Xia Qing, Liu Mei. Power system load forecasting[M]. Beijing: China Electric Power Press, 2007: 241-250(in Chinese).
- [2] 牛东晓,曹树华,卢建昌,等.电力负荷预测技术及其应用[M].2版.北京:中国电力出版社,2009:1-8.
Niu Dongxiao, Cao Shuhua, Lu Jianchang, et al. Power load forecasting technology and its application[M]. 2nd ed. Beijing: China Electric Power Press, 2009: 1-8(in Chinese).
- [3] 肖白,周潮,穆钢.空间电力负荷预测方法综述与展望[J].中国电机工程学报,2013,33(25):78-92.
Xiao Bai, Zhou Chao, Mu Gang. Review and prospect of the spatial load forecasting methods[J]. Proceedings of the CSEE, 2013, 33(25): 78-92(in Chinese).
- [4] 周建中,张亚超,李清清,等.基于动态自适应径向基函数网络的概率性短期负荷预测[J].电网技术,2010,34(3):37-41.
Zhou Jianzhong, Zhang Yachao, Li Qingqing, et al. Probabilistic short-term load forecasting based on dynamic self-adaptive radial basis function network[J]. Power System Technology, 2010, 34(3): 37-41(in Chinese).
- [5] 师彪,李郁侠,于新花,等.基于改进粒子群-模糊神经网络的短期电力负荷预测[J].系统工程理论与实践,2010,30(1):157-166.
Shi Biao, Li Yuxia, Yu Xinhua, et al. Short-term load forecasting based on modified particle swarm optimizer and fuzzy neural network model[J]. Systems Engineering-Theory & Practice, 2010, 30(1): 157-166(in Chinese).
- [6] 雷绍兰,孙才新,周淦,等.基于径向基神经网络和自适应神经模糊系统的电力短期负荷预测方法[J].中国电

- 机工程学报, 2005, 25(22): 78-82.
- Lei Shaolan, Sun Caixin, Zhou Quan, et al. Short-term load forecasting method based on RBF neural network and anfis system[J]. Proceedings of the CSEE, 2005, 25(22): 78-82(in Chinese).
- [7] 牛东晓, 魏亚楠. 基于 FHNN 相似日聚类自适应权重的短期电力负荷组合预测[J]. 电力系统自动化, 2013, 34(3): 54-57.
- Niu Dongxiao, Wei Yinnan. Short-term power load combinatorial forecast adaptively weighted by FHNN similar-day clustering[J]. Automation of Electric Power Systems, 2013, 34(3): 54-57(in Chinese).
- [8] Cristianini N, Shawe-Taylor J. An introduction to support vector machines and other kernel-based learning methods [M]. Cambridge: Cambridge University Press, 2000: 98-106.
- [9] 李瑾, 刘金朋, 王建军, 等. 采用支持向量机和模拟退火算法的中长期负荷预测方法[J]. 中国电机工程学报, 2011, 31(16): 63-66.
- Li Jin, Liu Jinpeng, Wang Jianjun, et al. Mid-long term load forecasting based on simulated annealing and SVM algorithm[J]. Proceedings of the CSEE, 2011, 31(16): 63-66(in Chinese).
- [10] 葛少云, 贾鸥莎, 刘洪. 基于遗传灰色神经网络模型的实时电价条件下短期电力负荷预测[J]. 电网技术, 2012, 36(1): 224-229.
- Ge Shaoyun, Jia Ousha, Liu Hong. A gray neural network model improved by genetic algorithm for short-term load forecasting in price-sensitive environment[J]. Power System Technology, 2012, 36(1): 224-229(in Chinese).
- [11] 何耀耀, 许启发, 杨善林, 等. 基于 RBF 神经网络分位数回归的电力负荷概率密度预测方法[J]. 中国电机工程学报, 2013, 33(1): 93-98.
- He Yaoyao, Xu Qifa, Yang Shanlin, et al. A power load probability density forecasting method based on RBF neural network quantile regression[J]. Proceedings of the CSEE, 2013, 33(1): 93-98(in Chinese).
- [12] 何耀耀, 闻才喜, 许启发, 等. 考虑温度因素的中期电力负荷概率密度预测方法[J]. 电网技术, 2015, 39(1): 176-181.
- He Yaoyao, Wen Caixi, Xu Qifa et al. A method to predict probability density of medium-term power load considering temperature factor[J]. Power System Technology, 2015, 39(1): 176-181(in Chinese).
- [13] Koenker R, Bassett Jr G. Regression quantiles [J]. Econometrica, 1978, 46(1): 33-50.
- [14] 许启发, 蒋翠侠. 分位数局部调整模型及应用[J]. 数量经济技术经济研究, 2011, 28(8): 115-133.
- Xu Qifa, Jiang Cuixia. Quantile partial adjustment model and its application[J]. The Journal of Quantitative & Technical Economics, 2011, 28(8): 115-133(in Chinese).
- [15] Taylor J W. A quantile regression neural network approach to estimating the conditional density of multiperiod returns[J]. Journal of Forecasting, 2000, 19(4): 299-311.
- [16] Cannon A J. Quantile regression neural networks: Implementation in R and application to precipitation downscaling[J]. Computers & Geosciences, 2011, 37(9): 1277-1284.
- [17] Shin J, Kim Y, Lee J, et al. Estimating value at risk with semiparametric support vector quantile regression [J]. Computational Statistics, 2012, 27(4): 685-700.
- [18] 许启发, 张金秀, 蒋翠侠. 基于支持向量分位数回归多期 VaR 测度[J]. 系统工程学报, 2014, 29(2): 202-214.
- Xu Qifa, Zhang Jinxiu, Jiang Cuixia. Evaluating multiperiod VaR via support vector quantile regression [J]. Journal of Systems Engineering, 2014, 29(2): 202-214(in Chinese).
- [19] Takeuchi I, Furuhashi T. Non-crossing quantile regressions by SVM[C]//Proceedings of 2004 IEEE International Joint Conference on Neural Networks. Budapest: IEEE, 401-406.
- [20] Yuan Ming. GACV for quantile smoothing splines [J]. Computational Statistics & Data Analysis, 2006, 50(3): 813-829.
- [21] Price information[EB/OL]. 2014[2014-02-27]. <https://www.emcsg.com/MarketData/PriceInformation#priceDataView>.



何耀耀

收稿日期：2016-03-06。

作者简介：

何耀耀(1982), 男, 工学博士, 副教授, 硕士生导师, 主要从事智能优化方法在电力系统中的应用, hy-342501y@163.com;

刘瑞(1990), 女, 硕士研究生, 主要从事电力负荷预测, 308273188@qq.com;

撒奥洋(1980), 男, 工学博士, 工程师, 主要从事分布式电源的配电网保护, hanaoyang@163.com。

(编辑 邱丽萍)

Short-Term Power Load Probability Density Forecasting Method Based on Real Time Price and Support Vector Quantile Regression

HE Yaoyao¹, LIU Rui¹, HAN Aoyang²

(1. Hefei University of Technology; 2. Qingdao Power Supply Company Control Center, Shandong Electric Power Group)

KEY WORDS: smart grid; support vector quantile regression (SVQR); real-time price; probability density forecasting; kernel density estimation

In the environment of smart grid, short-term power load forecasting plays an important role in power system scheduling, operation and production planning. Renewable energy sources and distributed power are applied into power systems, which increases uncertainties in both generation and demand sides. It is urgent to address these uncertainties of load forecasting. A probability density forecasting method is proposed based on real-time price and support vector quantile regression (SVQR). We apply quantile regression to support vector regression model, and then propose an optimization model of SVQR as follows:

$$\min_{\omega, b, \tau} \frac{1}{2} \|\omega\|^2 + C \sum_{t=1}^k \rho_{\tau}(y_t - b_{\tau} - \beta_{\tau}^T u_t - \omega_{\tau}^T \phi(x_t)) \quad (1)$$

where C is penalty parameters, b is the threshold value, and Lagrange function is constructed by shim in order to solve the optimization problem (1). The result of the problem is as follows:

$$\begin{cases} \omega_{\tau} = \sum_{t=1}^k (\alpha_t - \alpha_t^*) \phi(x_t) \\ (b_{\tau}, \beta_{\tau})^T = (U^T U)^{-1} U^T (y - K(\alpha - \alpha^*)) \\ Q_{y_t}(\tau | u_t, x_t, \eta) = b_{\tau} + \beta_{\tau}^T u_t + K_t(\alpha - \alpha^*) \end{cases} \quad (2)$$

where α, α^* are the best Lagrange multiplier, matrix U is equal to $(1, u_t^T)$, u is the influence factors of load forecasting, and K_t is the kernel matrix of the input space.

In the case study, the historical load and real-time price data are provided by Singapore network, including the historical load data from April 7, 2014 to April 16, 2014 and the real-time price data from April 7, 2014 to April 15, 2014. Predicted results of 24 load periods on

April 16, 2014 are obtained by SVQR method. Tab.1 shows the forecasting errors of SVQR, support vector regression (SVR) and radical basis function quantile regression (RBFQR) method. The prediction results and prediction intervals based on real-time price and SVQR are showed in Fig 1.

It can be seen that the predicted results of mode by SVQR method are superior to other methods, no matter whether the real-time power price is considered or not. Fig.1 demonstrates the actual values always fall in the prediction interval, and the predicted results of mode are close to the true value curve, which illustrates the proposed method is capable of accurately depicting power load fluctuations.

Tab. 1 Forecasting errors of SVR, SVQR and RBFQR

Algorithm	Without considering real-time power price		Considering real-time power price	
	MAPE/%	MRPE/%	MAPE/%	MRPE/%
SVR	2.15	6.42	2.04	9.95
SVQR(mode)	1.16	2.62	0.80	1.63
RBFQR(mode)	2.53	4.83	1.51	3.56




Fig. 1 Prediction results and prediction intervals based on real-time price and SVQR